ETT変圧器オイル温度予測PoC報告レポート

担当者:鎌田 佑
提出日:2026-04-23

Agenda

1. 課題の背景と技術アプローチ
2. データセットと EDA の主要な知見
3. モデル選定の根拠
4. 実験設定
5. 実験結果
6. モデル別の詳細考察
7. 設計上の主要な工夫
8. 現時点の限界と今後の改善方針
9. 実運用への提言
10. まとめ

1. 課題の背景と技術アプローチ

ビジネス課題を数理的問題に落とし込む

- ビジネス課題：事後対応型の保全から予測型予防保全へ移行したい

- 技術課題：変圧器オイル温度（OT）の将来値を精度良く予測できるか？」
  - **Step1.** データからどんなパターンが読み取れるか？（EDA）
  - **Step2.** どのモデルが最も適切か？（モデル選定）
  - **Step3.** どのくらいの誤差で予測できるか？（精度評価）
  - **Step4.** PoC 結果は実運用に耐えうるか？（実用判断）

分析の前提と仮定

- **ETT 4 データセット（ETTh1 / ETTh2 / ETTm1 / ETTm2）:** 頻度（1 h / 15 min）と負荷特性で汎化性能を検証
- **訓練: 検証: テスト = 12: 4: 4（ヶ月）:** ETT 論文（Zhou et al., 2021）に準拠
- **多変量入力・単変量出力:** 負荷特徴量6列が OT と高い相関関係
- **予測ホライズン = 24 / 48 / 96 / 168（h）:** 日次点検から週次保全計画までの実務サイクルに対応

2. データセットと EDA の主要な知見

データセット概要

ETT 4 データセット（Zhou et al., 2021）

- **ETTh1 / ETTh2**：1 時間粒度、17,420 行（約 2 年分）
- **ETTm1 / ETTm2**：15 分粒度、69,680 行（同期間・高解像度）

特徴量・目的変数

- **入力**：電気負荷 6 系統（HUFL, HULL, MUFL, MULL, LUFL, LULL）
- **出力（目標）**：OT（変圧器オイル温度、単変量）

予測ホライズン（共通）

- 24 / 48 / 96 / 168 steps — 日次点検〜週次保全計画に対応

EDA ① データ概要・基本統計

特徴量	平均	標準偏差	最小値	最大値	歪度
HUFL	7.38	7.07	−22.71	23.64	−1.38
MUFL	4.30	6.83	−25.09	17.34	**−1.61**
LUFL	3.07	1.16	−1.19	8.50	+1.27
OT（目標）	**13.32**	**8.57**	**−4.08**	**46.01**	+0.97

- OTの範囲は約50°C（−4.08〜46.01）
  - 単純な閾値監視では季節変動で誤報リスク増
- HUFL・MUFLは左裾が重いため、突発的低負荷・停電状態が存在
- ADF検定：p=0.0083で統計的に定常（差分変換不要）

EDA ② トレンド・季節・残差成分

STL 分解の結果（ETTh1 を代表例）

- **トレンド**: 夏 ≈ 35°C、冬 ≈ 5°C — 年次で約 30°C の振幅
- **日次季節**: 日中（10〜16 時）高、深夜（2〜5 時）低（±2〜4°C）
- **残差**: 比較的小さく、純粋なランダム成分は少ない

示唆

- 長期トレンド＋日次周期が支配 → 訓練/テストで季節が跨ぐと分布シフト顕在化

EDA ③ 季節性・特徴量相関

成分	観察された特徴
トレンド	夏（7〜9月）〜35°C、冬（12〜2月）〜5°C（年次で約 30°C 差）
日次季節成分	日中（10〜16時）高、深夜（2〜5時）低 ±2〜4°C
残差	比較的小さく、純粋なランダム成分は少ない

OT と特徴量の Pearson相関係数

- MUFL：0.82 … 最重要（中圧側有効負荷が直結）
- HUFL： 0.69 / LUFL：0.57 / MULL：0.53 / HULL：0.37 / LULL：0.31 → 全特徴量が正相関 → 多変量入力が有利

EDA ④ 自己相関（ACF）分析

OT の自己相関の特徴（ETTh1）

- **ラグ 1〜6 h:** 非常に強い正相関（> 0.9）— 直近数時間が最重要
- **ラグ 24 h:** 強い正相関（≈ 0.6〜0.7）— 日次周期
- **ラグ 48〜72 h:** 中〜弱中程度（≈ 0.3〜0.5）— 相関が持続
- **ラグ 168 h:** 弱い正相関（≈ 0.2〜0.3）— 週次周期を確認

示唆

- 入力窓 96 h で日次・準週次周期まで十分にカバー可能

技術的難題：分布シフト

訓練 vs テストの温度分布のズレ

- 訓練期間（2016-07 ～ 2017-06）夏・秋
  - OT 平均 約 15～20°C
- テスト期間（2017-11 ～ 2018-03）冬・春
  - OT 平均 約 5～10°C

➡ 約 10°C の差

技術的難題：分布シフト

対処：RevIN（Reversible Instance Normalization）

- 各サンプル（入力窓　96h）単位でインスタンス内の平均・標準偏差で正規化し、出力後に逆変換を行う。

  →「温度の絶対値」ではなく「相対的な変化パターン」を学習できる

3. モデル選定の根拠

モデル選定

4 階層のベースライン階段

- **Naive / MovingAvg**：ルールベース（params 0）— 最低ライン
- **LSTM**：RevIN → LSTM(128, 2L) → Linear（21 万 params）
- **Transformer**：RevIN → Pre-LN Enc×3（69 万 → 246 万 @168h）
- **PatchTST**：RevIN → Patch(16/8) → Enc×3（64 万 → 85 万）

選定の狙い

- 古典 → 逐次 → 全注意 → パッチ注意の段階比較で DL の付加価値を定量化

4. 実験設定

実験設定

共通設定

- **対象**: ETTh1 / ETTh2 / ETTm1 / ETTm2（全 4 データセット）
- **予測ホライズン**: 24 / 48 / 96 / 168 steps
- **入力窓**: 96 steps（h: 96 時間、m: 24 時間）
- **訓練:検証:テスト**: 12 : 4 : 4 ヶ月（ETT 論文準拠）

評価指標

- **MAE（°C）**: 主指標 — 絶対誤差で解釈容易
- **sMAPE（ε = 1.0）**: OT 最小 −4.08°C で MAPE 分母 ≈ 0 を回避

再現性

- seed = 42 固定 + DataLoader に torch.Generator 渡し

5. 実験結果

実験結果 ① ETTh1 / ETTh2（1 h）

ETTh1 — MAE（°C）

- **LSTM**：1.18 / 1.43 / 1.67 / 1.88（24/48/96/168 h）— 最良
- **Naive**：1.25 / 1.54 / 1.84 / 2.09
- **Transformer**：1.24 / 1.54 / 1.93 ⚠️ / 2.06（96 h で Naive 割れ）
- **PatchTST**：1.28 / 1.55 / 1.72 / 2.09

ETTh2 — MAE（°C）

- **LSTM**：2.44 / 2.89 / 3.42 / 4.13 — 最良
- **Naive**：4.03 / 4.36 / 4.73 / 5.14
- **PatchTST**：2.58 / 3.13 / 3.59 / 4.21

実験結果 ② ETTm1 / ETTm2（15分）

ETTm1 — MAE（°C） 24 s = 6 h、168 s = 42 h

- **LSTM：**0.69 / 0.92 / 1.19 / 1.43 — 最良
- **Naive：**0.71 / 0.99 / 1.25 / 1.50
- **PatchTST：**0.69 / 0.98 / 1.26 / 1.48

ETTm2 — MAE（°C）

- **LSTM：**1.21 / 1.90 / 2.33 / 2.77 — 最良
- **Naive：**2.34 / 3.70 / 4.07 / 4.49
- **PatchTST：**1.23 / 1.87 / 2.46 / 2.80（48 s のみ LSTM と同等）

横断比較：LSTM vs Naive（24 steps）

改善率（MAE）

- **ETTh1：**1.18 vs 1.25 °C → −6 %
- **ETTh2：**2.44 vs 4.03 °C → −39 %
- **ETTm1：**0.69 vs 0.71 °C → −3 %
- **ETTm2：**1.21 vs 2.34 °C → −48 %

解釈：DL の優位性はデータの難しさに比例

- ETTh1 / ETTm1 — 安定周期 → Naive が既に強力
- ETTh2 / ETTm2 — 変動大で Naive 追随不可、DL が大幅改善

6. モデル別の詳細考察

モデル別の詳細考察

LSTM が最強だった理由

- RevIN と相性良好な逐次モデル ー 相対変化を素直に学習
- params 21 万と小型で過学習耐性が高い

Transformer の弱点

- **params 爆発**: 24 h = 69 万 → 168 h = 246 万（約 3.6 倍）
- **ETTh1 96 h で Naive 割れ** ⚠️: 大 params × 分布シフトで過学習

PatchTST の位置付け

- Transformer より頑健（Naive 割れ無し）、ただし LSTM には及ばず

7. 設計上の主要な工夫

設計上の主要な工夫

① 分布シフトへの対処 — RevIN

- 入力窓単位の平均・標準偏差で正規化 → 逆変換で絶対値復元
- 夏/冬間の約 10°C シフトを「相対変化の学習」に置換

② 評価指標の工夫 — sMAPE（ε = 1.0）

- OT 最小 −4.08°C で通常 MAPE の分母 ≈ 0 問題が発生
- 対称化 + ε 付きで 0 近傍でも安定評価

③ 再現性の徹底

- seed = 42 + DataLoader の Generator で順序も再現

8. 現時点の限界と今後の改善

現時点の限界と今後の改善

現時点の限界

- **不確実性の未定量化**: 点予測のみ — 予測区間や信頼度なし
- **公開データのみ**: ETT は単一の中国変電所（2016〜2018）由来
- **外生変数未利用**: 気温・湿度など天候データ未反映

今後の改善方針

- **MC Dropout / Quantile Loss**: 不確実性定量化で自信度付き予測
- **実センサーデータ再学習**: 国内変電所で転移性を検証
- **外生変数の取り込み**: 気象 API 連携で先行説明変数を追加

9. 実運用への提言

実運用への提言

PoC 結論：LSTM + RevIN を本番候補に

- 4 データセット全てで最良 or 同等 — 汎用性を確認
- params 21 万と軽量 → CPU 推論でもリアルタイム対応可

運用段階の推奨ステップ

- **Phase 1（1〜3 ヶ月）：** シャドー運用 — 既存監視と並行ロギング
- **Phase 2（3〜6 ヶ月）：** アラート統合 — 閾値超過予測で点検推奨通知
- **Phase 3（6 ヶ月〜）：** 予防保全計画への組み込み（保守スケジュール最適化）

10. まとめ

まとめ

主要な結論

- **最良モデル**: LSTM — 全 4 データセット・全ホライズンで最高 or 同等
- **最大の課題**: 分布シフト（夏/冬 ≈ 10°C のズレ） → RevIN で対処
- **Transformer の弱点**: 長期 pred_len で params 爆発 → Naive 割れ

改善率の要点（LSTM vs Naive, 24 steps）

- 難しい ETTh2 −39 %、ETTm2 −48 % — 大幅改善
- 安定な ETTh1 / ETTm1 は −3〜−6 % と控えめ

次のステップ

- 不確実性定量化（MC Dropout）＋ 実センサーデータで再学習

参考文献

- **Zhou et al., 2021**: "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting." *AAAI 2021.* — ETTh1 データセット原著
- **Kim et al., 2022**: "Reversible Instance Normalization for Accurate Time-Series Forecasting against Distribution Shift." *ICLR 2022.* — RevIN 原著
- **Nie et al., 2023**: "A Time Series is Worth 64 Words." *ICLR 2023.* — PatchTST 原著
- **Vaswani et al., 2017**: "Attention Is All You Need." *NeurIPS 2017.* — Transformer 原著
- **Xiong et al., 2020**: "On Layer Normalization in the Transformer Architecture." *ICML 2020.* — Pre-LN の理論的根拠
- 「PyTorchで乱数のシードを固定する方法と、GPUの非決定的演算への対処」*Qiita* (https://qiita.com/TokyoMickey/items/63c4053740ab1f3f28a2)